R 语言基础（五）

随机模拟与正态近似

郑泽靖

北京师范大学统计学院

2026 年秋季学期

回顾：平均值与频率

输入代码

```
x <- c(0, 1, 1, 0, 1)
mean(x)
mean(x == 1)
```

Console 输出

```
[1] 0.6
[1] 0.6
```

`mean(x)` 计算平均值。

对逻辑值求平均时，
`TRUE` 按 1 计算，`FALSE` 按 0 计算。
因此可得到条件成立的频率。

均匀分布随机数：runif()

生成区间 $(0, 1)$ 上均匀分布的随机数。

输入代码

```
x <- runif(10, 0, 1)
x
mean(x)
```

- 第一个参数 10 是生成的个数。
- 后两个参数 0、1 是区间端点。
- 重复运行通常会得到不同结果。

正态分布随机数：rnorm()

生成标准正态分布 $N(0,1)$ 的随机数。

输入代码

```
x <- rnorm(10, 0, 1)
x
```

- 10 是生成的个数，0 是均值，1 是标准差。
- 标准正态随机数可以取正值，也可以取负值。

大数定律

设 $X_1, \ldots, X_n$ 是 X 的独立、同分布重复观测，且 X 的数学期望为有限数。

$$\lim_{n\to\infty} \frac{1}{n} \sum_{k=1}^{n} X_k = \mathrm{E}(X)$$

上述等式成立的概率为 1。

可以用大量重复观测的平均值估计数学期望。

本讲通过计算与图形理解结论，不讨论证明。

均匀分布的样本平均值

对 $X \sim U(0,1)$，有 $\mathrm{E}(X) = 0.5$。

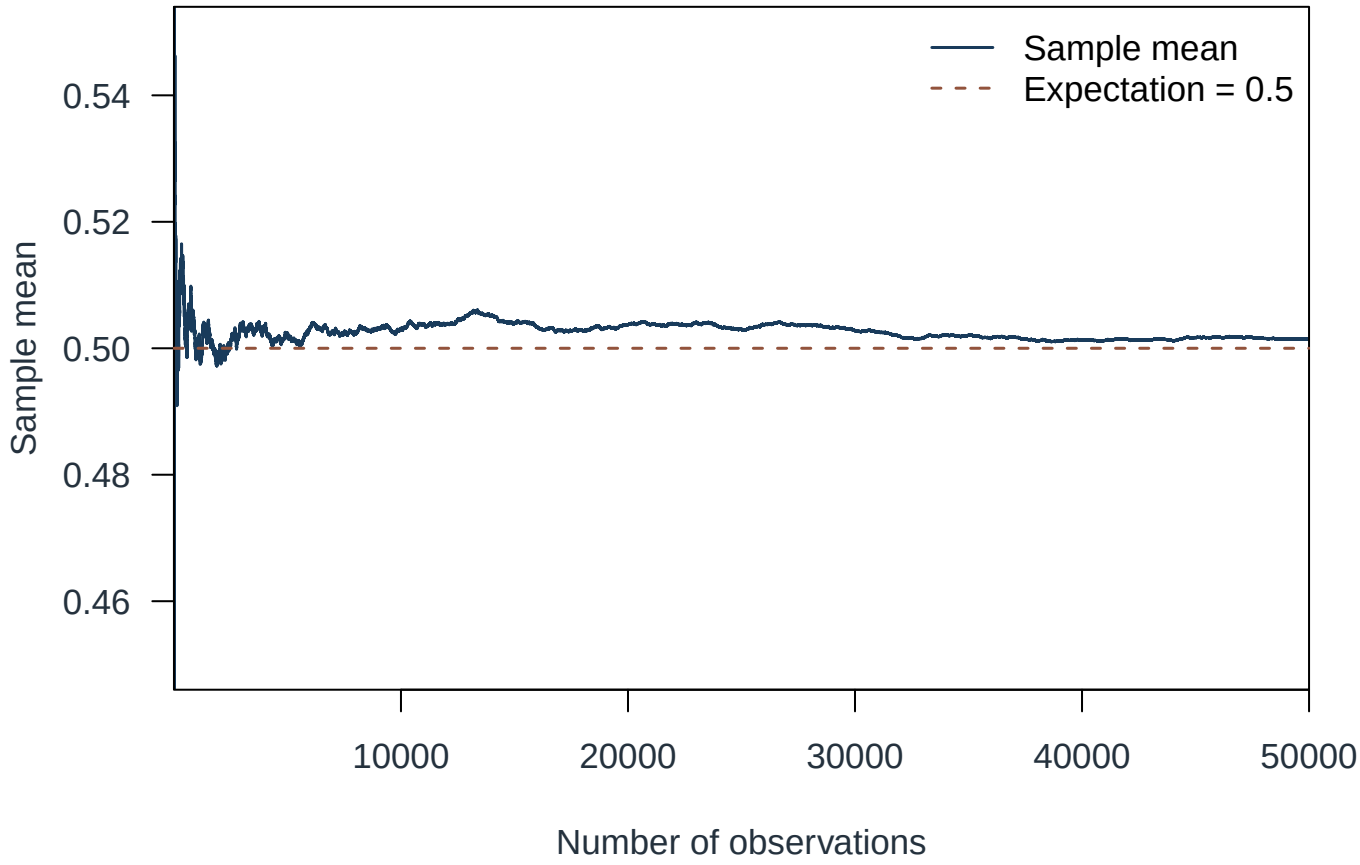
输入代码

```
x <- runif(50000, 0, 1)
mean(x[1:100])
mean(x[1:1000])
mean(x)
```

三次平均分别使用 100、1000、50000 个观测。

大样本下平均值通常更接近 0.5，
但误差不必逐次减小。

平均值随观测次数的变化



图形对应一次模拟。曲线会波动，不必单调接近 0.5。

矩的平均与频率

例 2.6.1：若 $\mathrm{E}(X^k)$ 有限，可用 X_i^k 的平均估计它。

输入代码

```
x <- runif(10000, 0, 1)
mean(x^2)
mean(x <= 0.5)
```

- 第一项估计 $\mathrm{E}(X^2)$。
- 第二项计算 $X \leq 0.5$ 的频率，估计其概率。

例 2.6.2 的含义：频率是 0、1 取值的平均，能用于估计概率。

经验分布函数

对给定的 t，经验分布函数表示
观测值中不大于 t 的比例。

$$F_n(t) = \frac{\text{不大于}t\text{的观测个数}}{n} \approx F(t) = \mathrm{P}(X \leq t).$$

输入代码

```
x <- runif(10000, 0, 1)
t <- 0.5
mean(x <= t)
```

例 2.6.3：对给定的 t，可用 $F_n(t)$ 估计 $F(t)$。

蒙特卡罗积分

蒙特卡罗方法：用随机模拟解决计算问题。

例 2.6.4：设 f 在 $[a, b]$ 上连续，取 $U \sim U(a, b)$。

$$\int_a^b f(x)\,\mathrm{d}x = (b-a)\mathrm{E}\{f(U)\}.$$

用 n 个均匀分布随机数 $U_1, \ldots, U_n$，得到

$$\int_a^b f(x)\,\mathrm{d}x \approx (b-a)\frac{1}{n}\sum_{k=1}^{n} f(U_k).$$

积分近似的计算步骤

1. 在积分区间 $[a, b]$ 中生成均匀随机数。
2. 计算每个随机数对应的函数值 $f(U_k)$。
3. 计算函数值的平均，再乘区间长度 $b - a$。

每次运行所用的随机数不同，近似值通常也不同。

增大模拟次数有助于提高精度，但一次结果不保证更接近目标值。

教材例 2.6.5：标准正态区间概率

设 $X \sim N(0,1)$，计算 $\mathrm{P}(0.1 < X < 2)$。

标准正态密度为

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$$

因此

$$\mathrm{P}(0.1 < X < 2) = \int_{0.1}^{2} \varphi(x)\,\mathrm{d}x.$$

可以用均匀随机数近似计算这个积分。

方法一：均匀随机数计算积分

输入代码

```
Y <- runif(10000, 0.1, 2)
c <- 1 / sqrt(2 * pi)
f <- c * exp(-(Y * Y) / 2)
p <- (2 - 0.1) * mean(f)
p
```

- `sqrt()` 计算平方根，`exp()` 计算指数函数。
- `pi` 是 R 中的圆周率常量。
- `f` 保存密度值，`p` 保存近似概率。

方法二：正态随机数计算频率

直接生成标准正态随机数，计算落入区间的比例。

输入代码

```
x <- rnorm(100000, 0, 1)
I <- x > 0.1 & x < 2
p <- mean(I)
p
```

`I` 保存每个随机数是否落在 $(0.1, 2)$ 中。

`mean(I)` 是条件成立的频率，近似所求概率。

用 pnorm() 核对

`pnorm(t, 0, 1)` 给出标准正态概率 $\mathrm{P}(X \leq t)$。

输入代码

```
pnorm(2, 0, 1) - pnorm(0.1, 0, 1)
```

Console 输出

```
[1] 0.437422
```

两种模拟方法都在估计约 0.4374 的同一个概率。

模拟值与计算值有差异，不需要与本页完全相同。

课堂练习一：重复模拟

1. 运行例 2.6.5 的两段模拟程序，各重复两次，记录近似概率。
2. 方法一把 10000 改为 100000，再运行一次。
3. 方法二把 100000 改为 10000，再运行一次。
4. 与 0.437422 比较，用一句话说明运行结果的差异。

使用 `R5-class.R` 第 5、6 段的完整程序。

练习一参考：两种计算程序

均匀随机数与密度值平均：

```
Y <- runif(100000, 0.1, 2)
f <- exp(-(Y * Y) / 2) / sqrt(2 * pi)
(2 - 0.1) * mean(f)
```

正态随机数与区间频率：

```
x <- rnorm(10000, 0, 1)
mean(x > 0.1 & x < 2)
```

两段程序的结果都应接近 0.4374。

第一节小结

- 随机数模拟重复观测，每次结果通常不同。
- 观测平均值可估计数学期望，
  观测频率可估计概率。
- 蒙特卡罗积分使用函数值平均与区间长度。
- 模拟次数增加时，误差仍可能局部增大。

例 2.6.5 的两种方法，都在计算
同一个正态区间概率。

第二节：样本平均值的分布

上一节用样本平均值估计数学期望。

$$\overline{X}_n = \frac{1}{n}\sum_{k=1}^{n} X_k.$$

若重新抽取一组样本，$\overline{X}_n$ 也会改变。

本节研究标准化后的样本平均值
如何用正态分布近似。

样本平均值的标准化

记 $\mu = \mathrm{E}(X)$、$\sigma^2 = \mathrm{D}(X) > 0$。

$$Z_n = \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} = \frac{\overline{X}_n - \mu}{\sigma/\sqrt{n}}.$$

- 减去 μ，使中心位于 0。
- 除以 $\sigma/\sqrt{n}$，使标准差为 1。

标准化后可与标准正态分布比较。

中心极限定理

设 $X_1, \ldots, X_n$ 是 X 的独立、同分布重复观测，且

$$0 < \sigma^2 = \mathrm{D}(X) < \infty.$$

对任意实数 t，有

$$\lim_{n \to \infty} \mathrm{P}(Z_n \leq t) = \Phi(t).$$

Φ 是标准正态分布函数。
当 n 较大时，用 $N(0,1)$ 近似 Z_n 的分布。

大数定律与中心极限定理

结论	本讲中的用途
大数定律	用样本平均值估计数学期望， 用频率估计概率。
中心极限定理	用标准正态分布近似 标准化样本平均值的分布。

后者不要求原变量 X 本身服从正态分布，
但需要定理中的重复观测与方差条件。

教材例 2.6.6：平均体重的概率

已知某大学女学生体重的均值为 51.96 kg，
标准差为 6.31 kg。

随机选择 36 名女大学生，
求平均体重超过 57 kg 的概率。

记 36 人的平均体重为 $\overline{X}$，用中心极限定理近似：

$$\mathrm{P}(\overline{X} > 57) \approx 1 - \Phi\left(\frac{\sqrt{36}(57 - 51.96)}{6.31}\right).$$

例 2.6.6 的 R 计算

输入代码

```
z <- sqrt(36) * (57 - 51.96) / 6.31
z
1 - pnorm(z, 0, 1)
```

Console 输出

```
[1] 4.792393
[1] 8.240182e-07
```

`e-07` 表示乘以 10^{-7}。

按教材的正态近似，所求概率很小。

例 2.6.6 的结果解释

- 计算对象是 36 人平均体重超过 57 kg 的概率。
- 标准化时使用平均值的标准差 $6.31/\sqrt{36}$。
- 结果是中心极限定理给出的近似值。

教材没有假设单个人的体重一定服从正态分布。
正态近似仍需满足重复观测等定理条件。

教材例 2.6.7：泊松样本的标准化均值

设 $X \sim \mathrm{P}(0.5)$，其均值、方差都为 0.5。

每组取 $n = 30$ 个重复观测，计算

$$\overline{X} = \frac{1}{30}\sum_{k=1}^{30} X_k, \qquad Z = \frac{\sqrt{30}(\overline{X} - 0.5)}{\sqrt{0.5}}.$$

重复生成 1000 组样本，得到 1000 个 Z 值。

将它们的经验分布函数与 Φ 比较。

生成 1000 组泊松样本

输入代码

```
n <- 30
y <- matrix(rpois(1000 * n, 0.5),
            1000, n)
z <- (rowSums(y) / n - 0.5) *
     sqrt(n / 0.5)
```

- `rpois()` 生成泊松分布随机数，参数 0.5。
- `y` 有 1000 行、n 列，每行是一组样本。
- `rowSums(y) / n` 是每组的样本平均值。

计算标准化均值的经验累计比例

输入代码

```
x <- seq(-3, 3, 0.1)
f <- c()
for (i in 1:length(x)) {
  f <- c(f, sum(z <= x[i]) / 1000)
}
phi <- pnorm(x, 0, 1)
```

`f` 保存各位置的经验累计比例。

`phi` 保存相同位置的标准正态累计概率。

经验分布与标准正态分布的比较

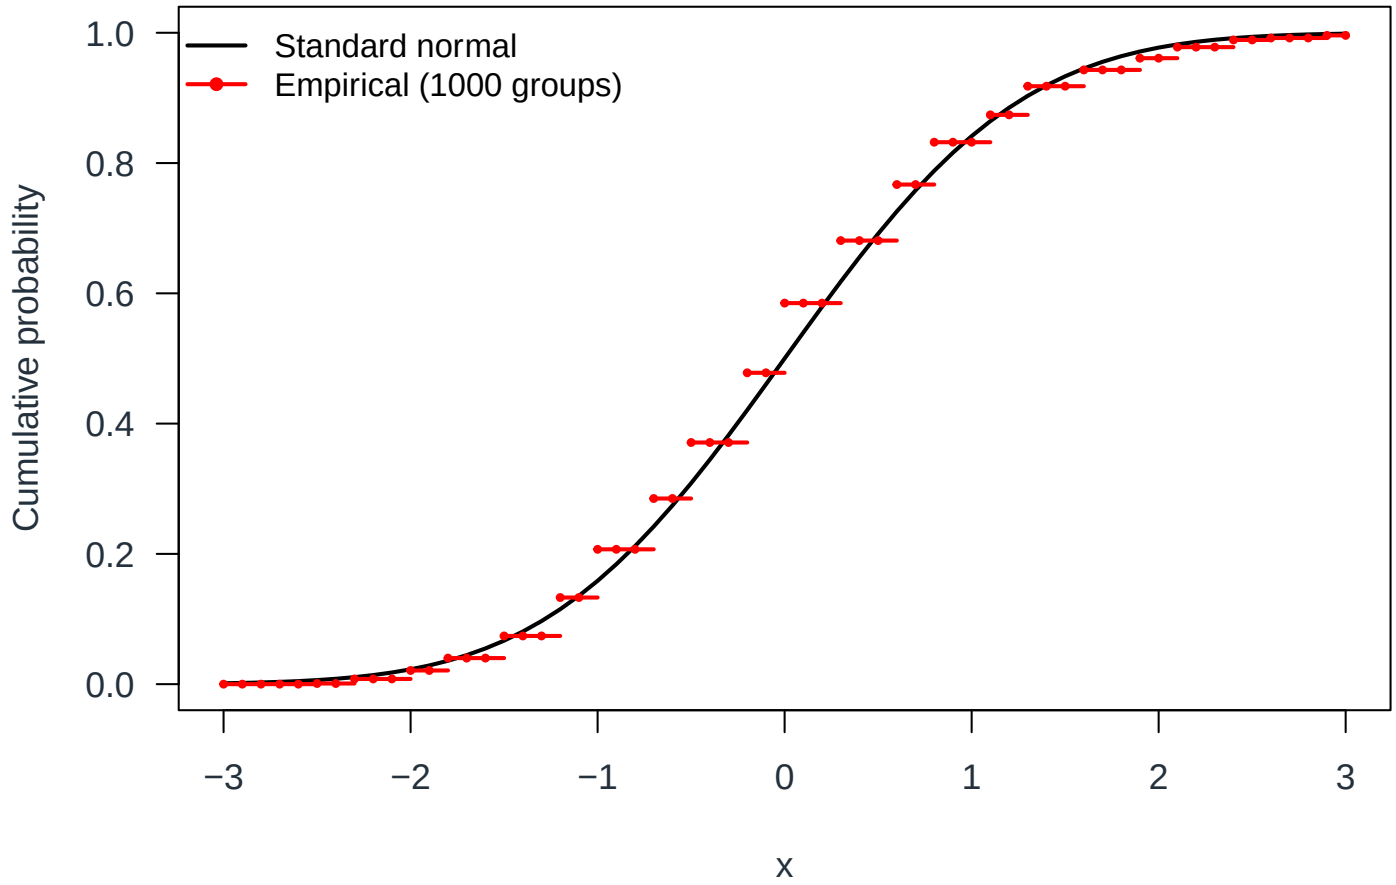
R5-class.R 已提供完整绘图段。核心代码为：

```
plot(x, phi, type = "l", ylim = c(0, 1))
for (i in 1:(length(x) - 1)) {
  lines(x[i:(i + 1)], c(f[i], f[i]),
        col = "red")
  points(x[i], f[i], pch = 20,
         col = "red")
}
```

黑线表示 Φ，红色线段与点表示经验累计比例。

本例重点是比较曲线，绘图参数不要求独立编写。

30 个观测的样本：一次模拟结果



两条曲线大体接近，但经验分布仍可见偏差与阶梯。

泊松模拟中的两个次数

数值	含义
每组 $n = 30$	每组 30 个观测， 计算一次样本平均值。
重复 1000 组	得到 1000 个标准化均值， 用来计算经验累计比例。

下一步只改变每组样本量 n，保持重复 1000 组。

课堂练习二：改变每组样本量

1. 运行 `R5-class.R` 的“泊松模拟”段，观察 $n = 30$ 的图形。
2. 将 `n <- 30` 改为 `n <- 300`，重新运行该段全部代码。
3. 保持每次 1000 组，比较两图中的经验分布与标准正态曲线。
4. 说明每组样本量与重复组数分别由哪个数表示。

使用给定程序。

练习二参考：需要重新计算的对象

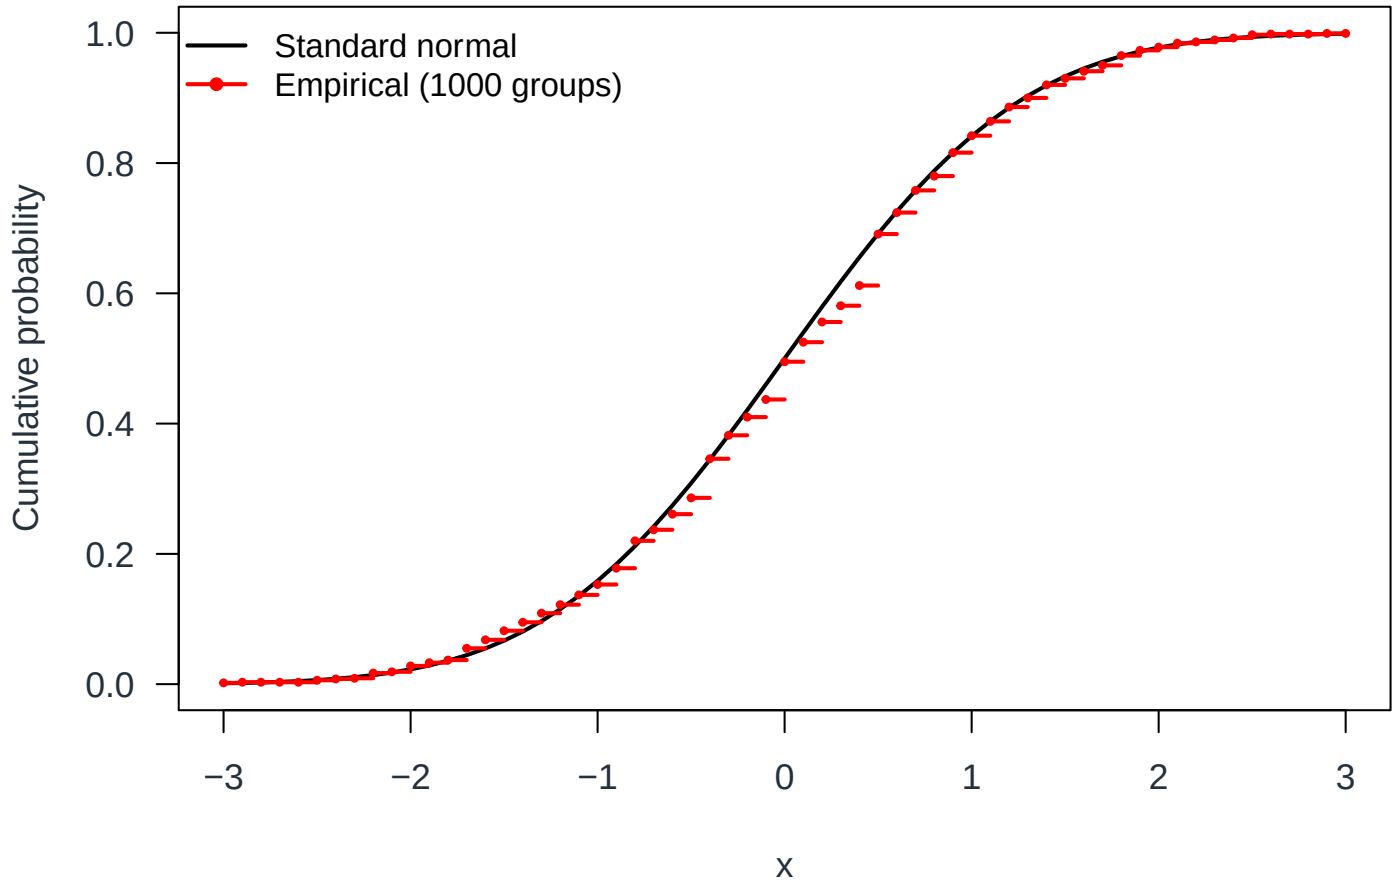
输入代码

```
n <- 300
y <- matrix(rpois(1000 * n, 0.5),
            1000, n)
z <- (rowSums(y) / n - 0.5) *
     sqrt(n / 0.5)
```

随后重新运行经验累计比例与绘图代码。

此时 y 有 1000 行、300 列，
仍得到 1000 个标准化均值。

300 个观测的样本：一次模拟结果



本轮模拟的经验分布更接近标准正态曲线，仍存在随机波动。

本讲操作核对

任务	本讲使用的方法
生成随机数	`runif()`、`rnorm()`、`rpois()`
估计期望与概率	数值平均、逻辑条件的平均
近似计算积分	区间长度乘函数值的平均
计算正态概率	`pnorm()` 与标准化
观察正态近似	标准化均值的经验分布与 Φ 比较

模拟结果应结合概率对象与条件解释。