# R 语言基础（六）

## 频数、频率与基本图形

郑泽靖

北京师范大学统计学院

2026 年秋季学期

# 课堂数据

本讲使用教材中的数据。

- 56 名学生的身高：频率直方图。
- 两届学生的成绩：不等组距与分布比较。
- 29 名学生的性别：频数、频率与分类图形。
- 55 辆汽车的车速：第一节课堂练习。

在 RStudio 中打开 `R6-data.R`，
选中相应数据段运行，后续直接使用数据名称。
本讲不要求逐项输入数据。

# 数据分组

- 组边界：将数据范围分成若干区间的分割点。
- 组距：相邻两个组边界的差。
- 等距分组：各组组距相同。
- 不等距分组：存在不同的组距。

先确定覆盖全部数据的范围，再选择组边界，最后统计每组中的数据个数。

# 频率直方图的柱高与面积

对某一组，设频数为 $n_i$，总样本量为 $n$。

$$\text{频率} = \frac{n_i}{n}, \qquad \text{柱高} = \frac{\text{频率}}{\text{组距}}.$$

$$\text{矩形面积} = \text{柱高} \times \text{组距} = \text{频率}.$$

各组矩形的总面积为 1。用频率近似概率，矩形顶边可以帮助观察总体密度的形状。

# hist() 的基本用法

```
hist(height, breaks = "Sturges",
     freq = FALSE)
```

| 参数 | 含义 |
| --- | --- |
| height | 数值型数据向量 |
| breaks | 分组规则或组边界向量 |
| freq = FALSE | 频率直方图，纵轴为频率/组距 |
| freq = TRUE | 分组频数条形图，纵轴为频数 |

默认分组规则为 "Sturges"。

实际分组仍需结合图形检查。

# 教材例 4.2.1：身高直方图

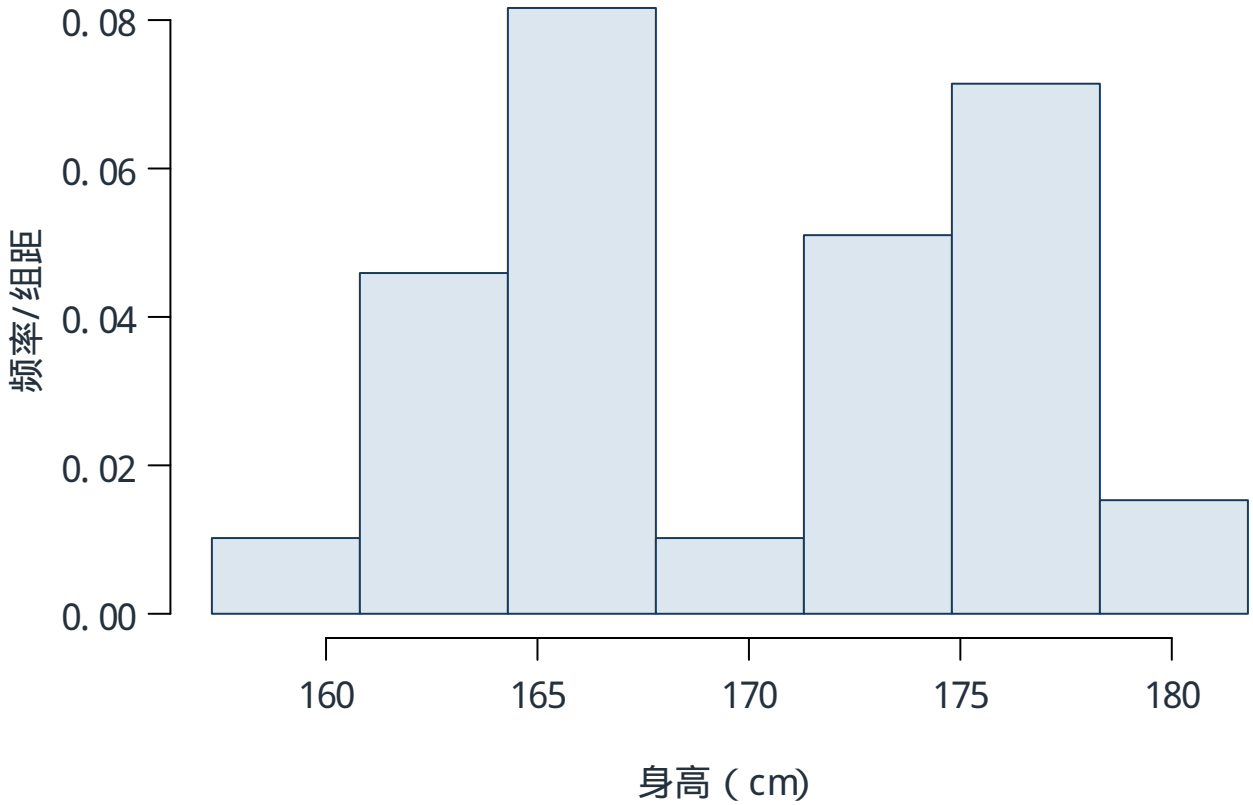
数据名称为 height，共 56 个身高值。

**输入代码**

```
g <- seq(157.3, 181.8, 3.5)
hist(height, breaks = g,
     freq = FALSE, main = "",
     xlab = "身高 (cm) ",
     ylab = "频率/组距")
```

main 设置标题，xlab 和 ylab 设置坐标轴名称。
main = "" 表示不另加图标题。

# 56 名学生的身高分布




每个矩形面积表示相应身高区间内学生的频率。

# 直方图的读取

本例在两个区间出现较高的矩形：

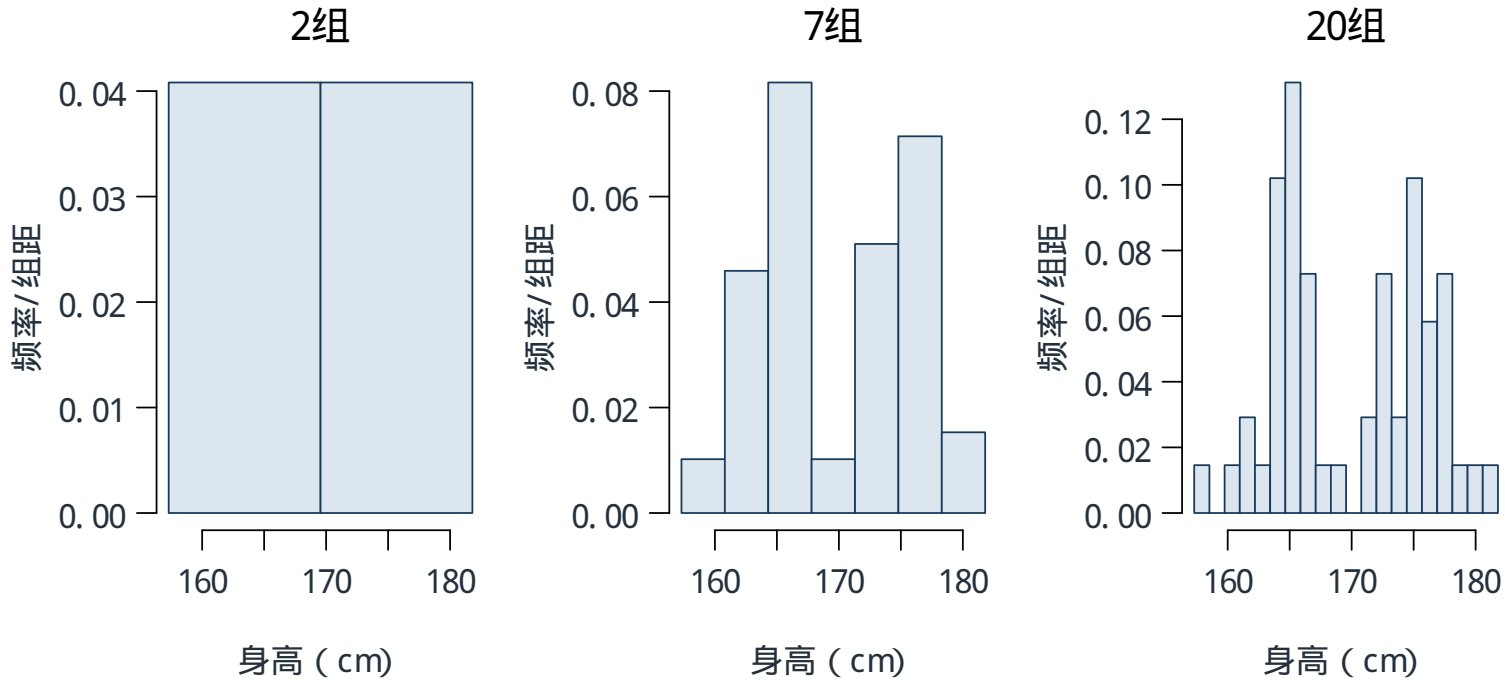
$$(164.3, 167.8], \qquad (174.8, 178.3].$$

图形呈现两个峰，整体不具有良好的对称性。

读图时可关注数据范围、对称性、峰的个数、中心位置及分散程度。读图结论来自本组样本。

# 分组数的选择

分组太少会掩盖细节，分组太多会使图形过于零碎。
教材给出的经验参考为 $k \approx 1 + \log_2 n$。




对 56 个观测，参考值约为 6.8，本例取 7 组。仍需结合图形检查分组是否合适。

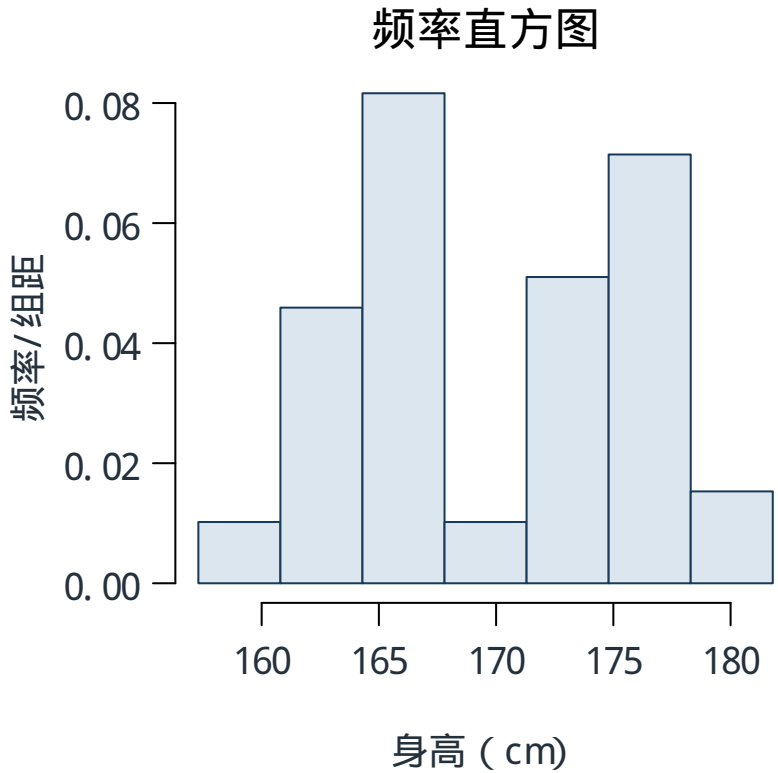
# 分组频数条形图

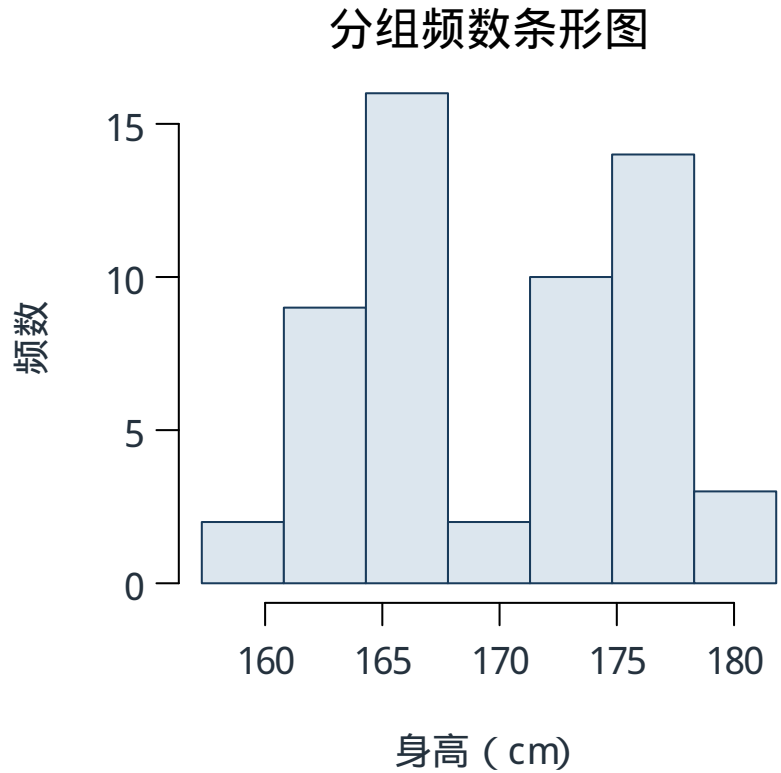
同样的身高数据与组边界，只修改 `freq`。

```
hist(height, breaks = g,
     freq = TRUE, main = "",
     xlab = "身高 (cm) ",
     ylab = "频数")
```

此时每根柱的高度表示该组中的学生人数。

# 等组距时的两种纵轴




本例各组组距相同，两图形状一致。
左图看频率/组距，右图看每组人数。

# 教材例 4.2.2：不等组距

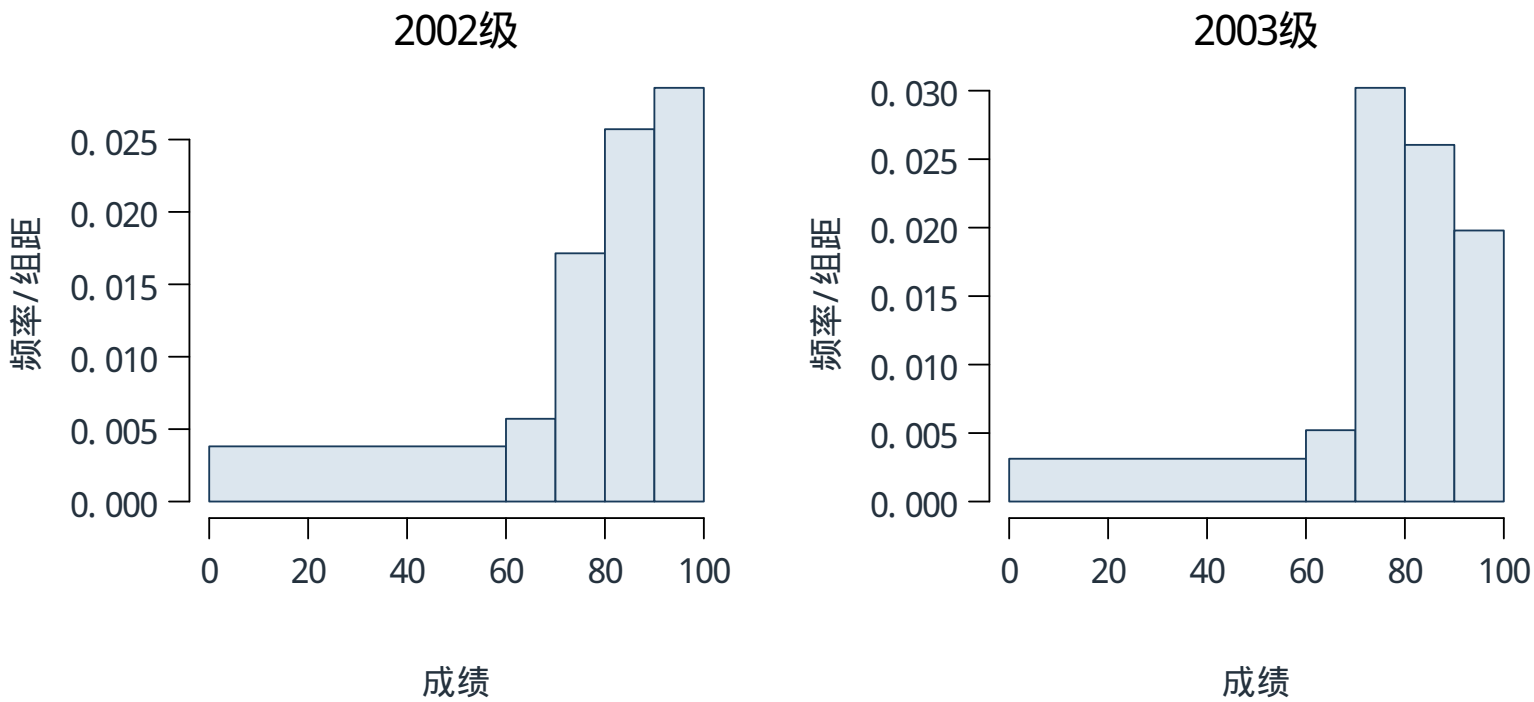
使用教材两届成绩 prob02、prob03。

```
hist(prob02, right = FALSE,
     breaks = c(0, 60, 70, 80, 90, 100),
     freq = FALSE, main = "2002级",
     xlab = "成绩", ylab = "频率/组距")

hist(prob03, right = FALSE,
     breaks = c(0, 60, 70, 80, 90, 100),
     freq = FALSE, main = "2003级",
     xlab = "成绩", ylab = "频率/组距")
```

`right = FALSE` 表示左闭右开，如 $[60, 70)$。

# 不等组距下的成绩比较




首组组距为 60，其余各组为 10。比较分布形状时，柱高应采用频率/组距，不能直接用频数代替。2002 级较高的密度在 90–100 分组，2003 级在 70–80 分组。

# 课堂练习一：汽车车速（12 分钟）

教材练习 4.10：55 辆汽车，数据为 speed。

1. 按下面的组边界绘制频率直方图。
2. 将组距由 5 改为 10，比较图形。
3. 说明纵轴含义，并描述车速的主要集中范围。

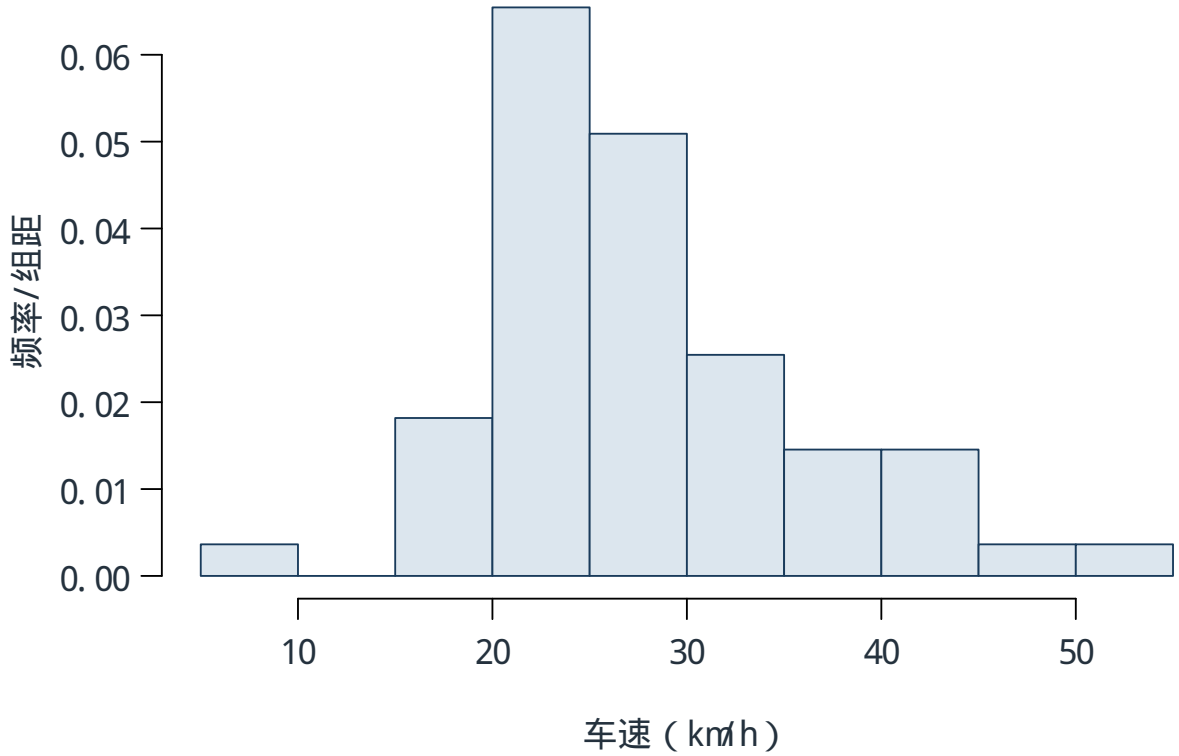
```
g1 <- seq(5, 55, 5)
hist(speed, breaks = g1, freq = FALSE,
     main = "", xlab = "车速 (km/h) ",
     ylab = "频率/组距")
g2 <- seq(5, 55, 10)
```

# 练习一参考：改变组距

```
g2 <- seq(5, 55, 10)
hist(speed, breaks = g2, freq = FALSE,
     main = "", xlab = "车速 (km/h) ",
     ylab = "频率/组距")
```

两种分组都使用同一批数据。组距改变时，柱高也随之改变，但各组矩形的总面积仍为 1。

# 练习一参考：车速分布




本组车速主要集中在 20–35 km/h 附近。
总体变量为该路段在所考察条件下通过车辆的车速。

# 第一节操作核对

- 能用 breaks 指定覆盖全部数据的组边界。
- 能区分频率直方图与分组频数条形图。
- 知道频率直方图的面积表示频率。
- 读图时同时查看分组方式与纵轴名称。

下一节：分类频数与频率、条形图与饼图。

# 分类数据的频数

教材案例 4.4 调查 29 名学生的性别。先运行数据脚本中的 `gender` 段。

```
a <- as.factor(gender)
u <- table(a)
u
```

**Console 输出**

```
a
女 男
17 12
```

`as.factor()` 将数据转为因子，`table()` 统计频数。类别顺序可能因系统而异，应按标签核对。

# 频数合计

addmargins() 在分类统计结果中添加合计。

```
addmargins(u)
```

**Console 输出**

```
a
  女   男 Sum
 17   12  29
```

女生 17 人，男生 12 人，合计 29 人。

# 分类数据的频率

`prop.table()` 将频数转为频率。

```
v <- prop.table(u)
addmargins(v)
```

**Console 输出**

```
a
       女        男      Sum
0.5862069 0.4137931 1.0000000
```

$$\text{女生频率} = 17/29, \qquad \text{男生频率} = 12/29.$$

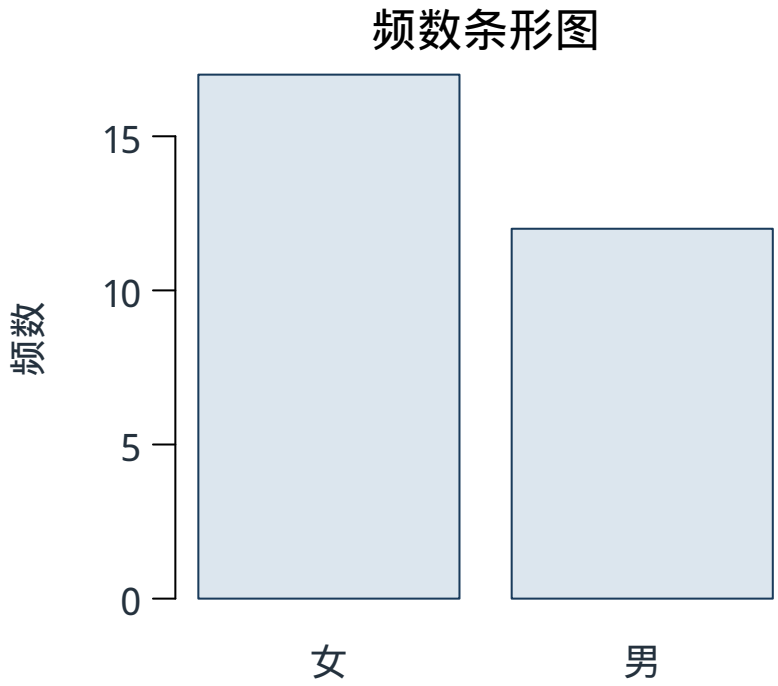
所有类别的频率合计为 1。

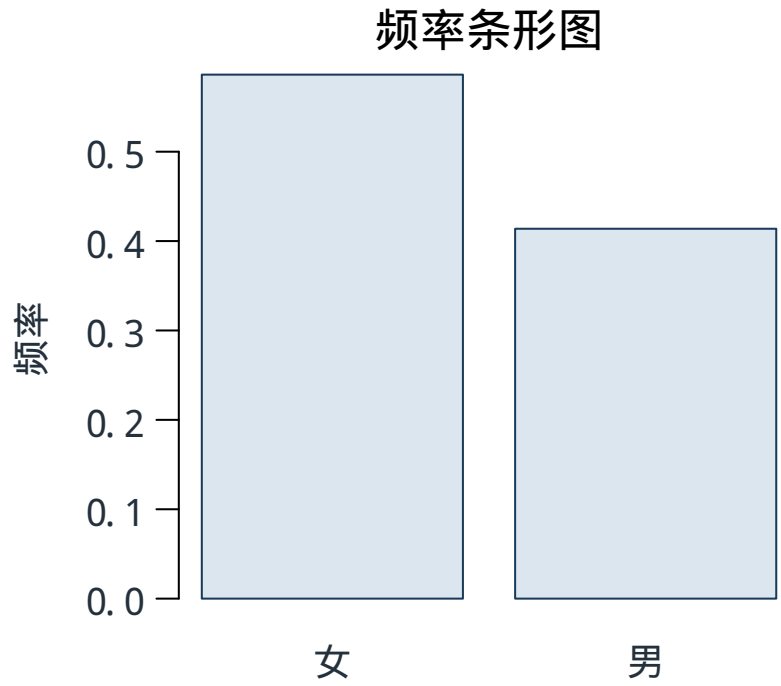
# 分类数据的条形图

```
barplot(u, main = "", ylab = "频数")
barplot(v, main = "", ylab = "频率")
```

- 条形高度分别表示频数或频率。
- 不同类别的条形相互分离。
- 纵轴从 0 开始，避免夸大类别间的差别。

# 频数条形图与频率条形图

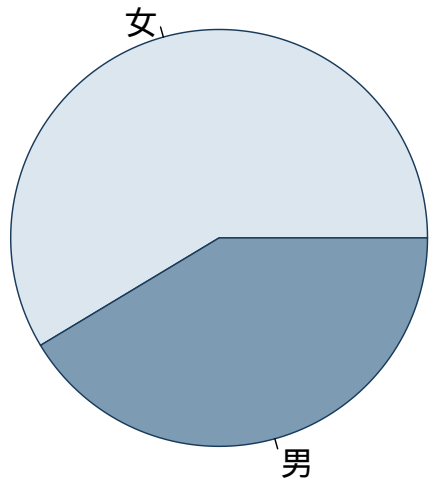



两图表达同一组分类统计结果，纵轴分别为人数与所占比例。

# 饼图

```
pie(u)
```




每个扇形的面积比例表示该类别的频率。女生所占比例较高，与频数表及条形图一致。

# 教材案例 4.5：性别与专业

69 名学生中，文科 29 人，理科 40 人。

```
x <- matrix(c(12, 19, 17, 21), nrow = 2)
colnames(x) <- c("男", "女")
rownames(x) <- c("文科", "理科")
y <- as.table(x)
y
```

**Console 输出**

```
     男 女
文科 12 17
理科 19 21
```

# 列联表的行与列

| | 男 | 女 | 合计 |
|---|---|---|---|
| 文科 | 12 | 17 | 29 |
| 理科 | 19 | 21 | 40 |
| 合计 | 31 | 38 | 69 |

`y` 的行是专业，列是性别。`t(y)` 交换行与列，便于改为按专业画图。

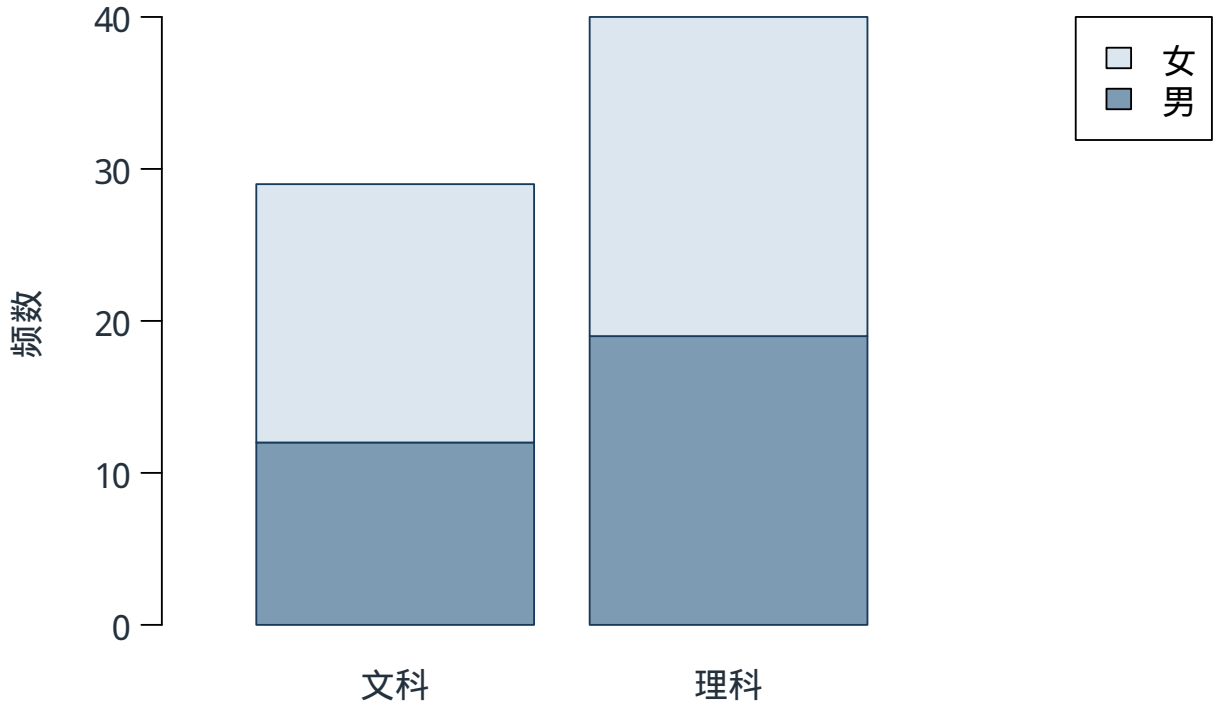
# 普通堆积条形图：代码

先按专业比较人数构成。

```
barplot(t(y),
        xlim = c(0, 3.5),
        legend.text = colnames(y),
        args.legend = list(x = "topright"),
        ylab = "频数")
```

`legend.text` 设置图例名称，`args.legend` 设置图例位置。`xlim` 为图例保留横向空间。

# 普通堆积条形图：人数




柱的总高度是该专业总人数，各段高度是男、女生人数。
理科总人数 40，文科总人数 29。

# 按专业计算性别比例

```
prop.table(t(y), margin = 2)
```

**Console 输出**

```
          文科       理科
男 0.4137931 0.4750000
女 0.5862069 0.5250000
```

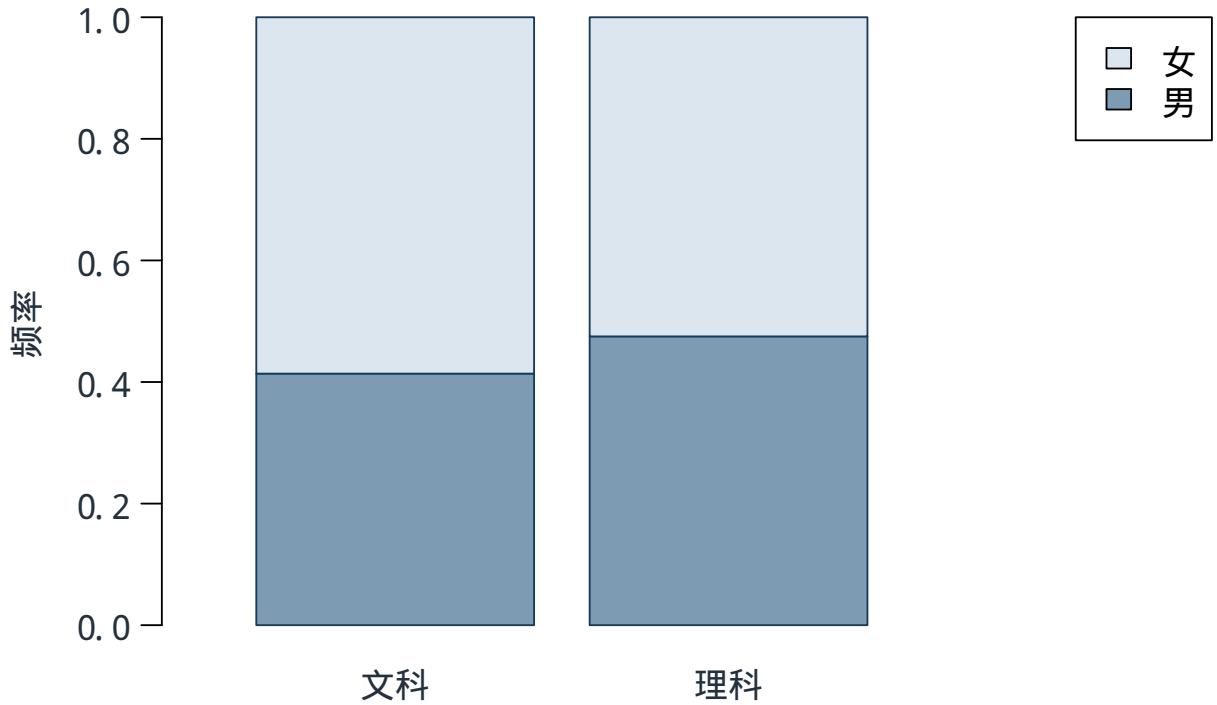
`margin = 2` 表示每一列分别计算比例，各列合计为 1。这里的分母分别为文科 29 人和理科 40 人。

# 等高堆积条形图：代码

```
barplot(prop.table(t(y), margin = 2),
        xlim = c(0, 3.5),
        legend.text = colnames(y),
        args.legend = list(x = "topright"),
        ylab = "频率")
```

把每个专业的人数换为该专业内部的性别比例，两根柱的总高度均为 1。

# 等高堆积条形图：比例




文科女生比例约为 0.59，理科女生比例为 0.525。此图便于比较比例，但不能由柱高比较专业总人数。

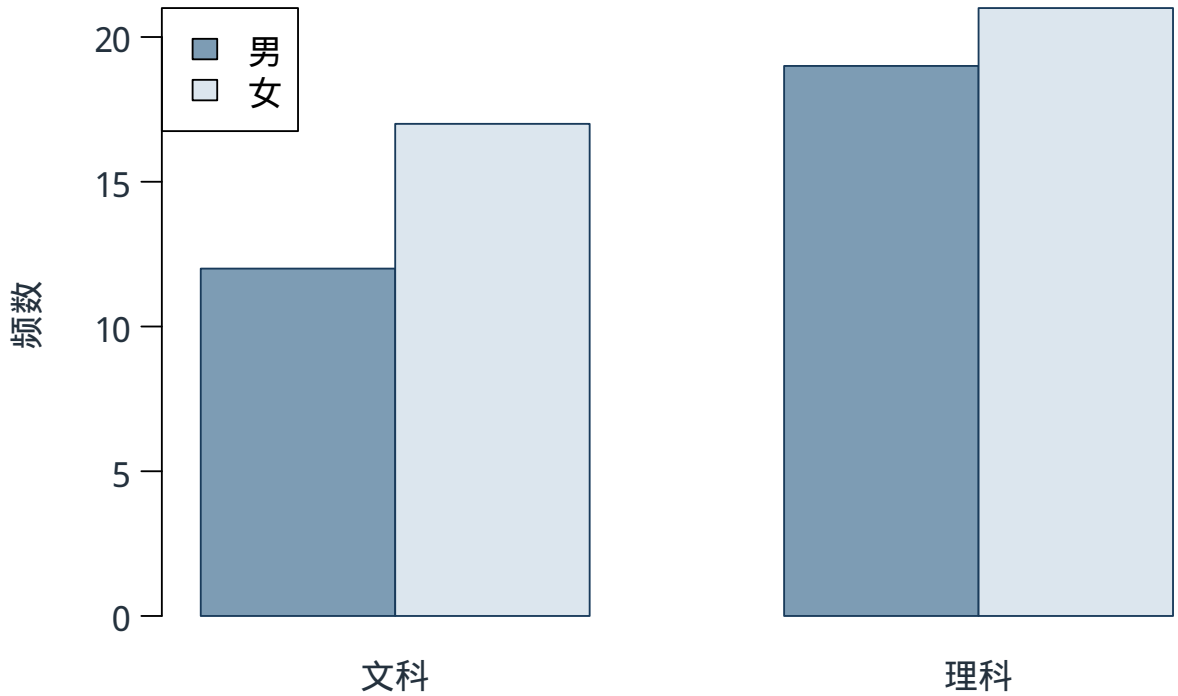
# 并列条形图：代码

令 `beside = TRUE`，同一专业的男、女生分别画成相邻的条形。

```
barplot(t(y), beside = TRUE,
        legend.text = colnames(y),
        args.legend = list(x = "topleft"),
        ylab = "频数")
```

与堆积方式相比，并列条形便于直接比较各专业男、女生的人数。

# 并列条形图：人数比较




同一专业内可比较男、女生人数，也可比较同一性别在两个专业中的人数。

# 交换分类方向的代码对照

按性别查看专业构成时，使用 `y`，图例改为行名。

```
barplot(y, xlim = c(0, 3.5),
        legend.text = rownames(y),
        args.legend = list(x = "topright"))
barplot(prop.table(y, margin = 2),
        xlim = c(0, 3.5),
        legend.text = rownames(y),
        args.legend = list(x = "topright"))
barplot(y, beside = TRUE,
        legend.text = rownames(y),
        args.legend = list(x = "topleft"))
```

# 课堂练习二：三个专业（12 分钟）

| 专业 | 男 | 女 | 合计 |
|---|---|---|---|
| 文科 | 15 | 25 | 40 |
| 理科 | 20 | 30 | 50 |
| 工科 | 25 | 15 | 40 |

```
z <- matrix(c(15, 20, 25, 25, 30, 15),
            nrow = 3)
rownames(z) <- c("文科", "理科", "工科")
colnames(z) <- c("男", "女")
```

以专业为横轴，参照前面的代码分别画普通堆积、等高堆积和并列条形图。比较总人数与性别比例。

# 练习二参考：三种绘图方式

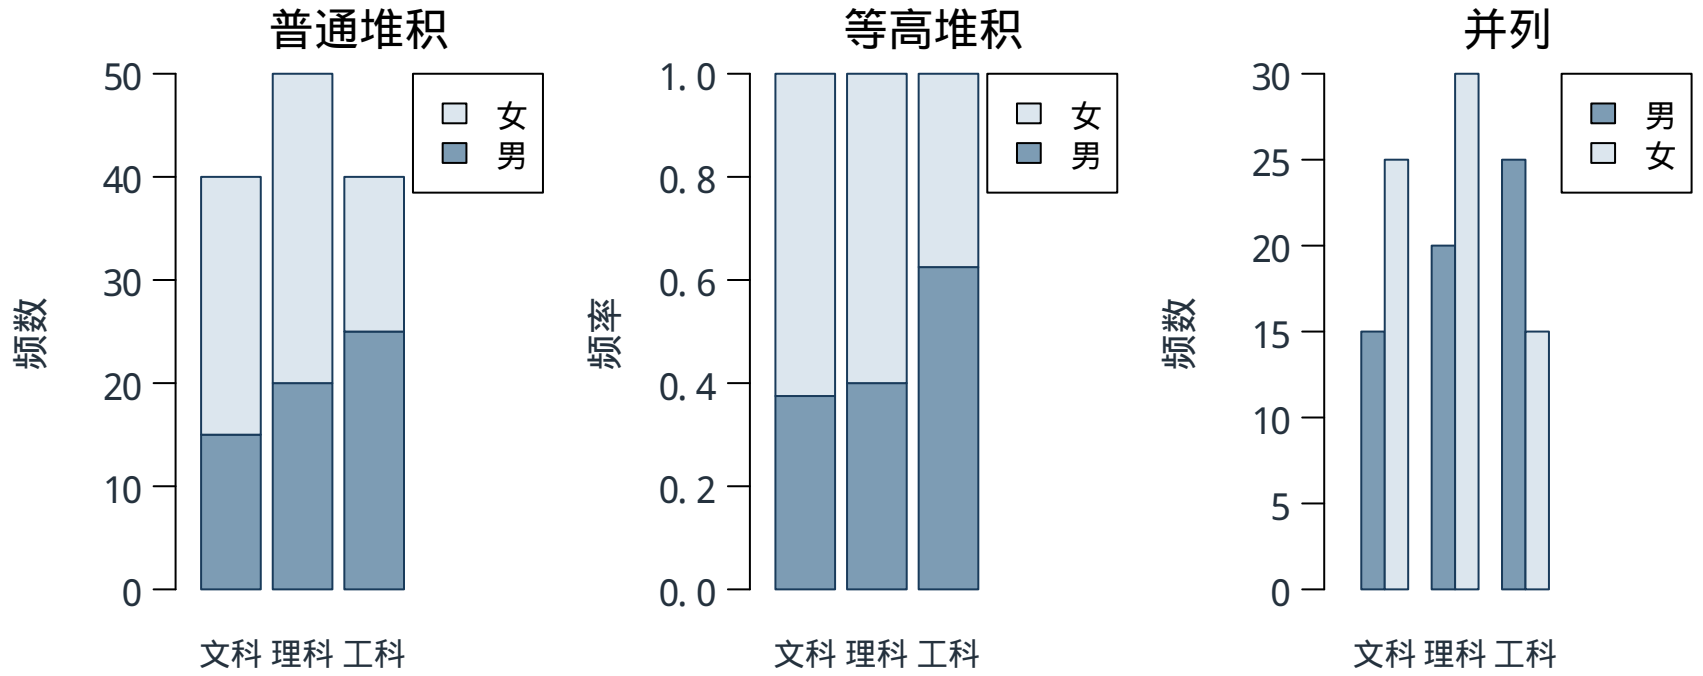
三段代码的图例设置相同，重点核对第一个参数。

```
barplot(t(z), xlim = c(0, 5),
        legend.text = colnames(z),
        args.legend = list(x = "topright"))

barplot(prop.table(t(z), margin = 2),
        xlim = c(0, 5),
        legend.text = colnames(z),
        args.legend = list(x = "topright"))

barplot(t(z), beside = TRUE, xlim = c(0, 12),
        legend.text = colnames(z),
        args.legend = list(x = "topright"))
```

# 练习二参考：数量与比例



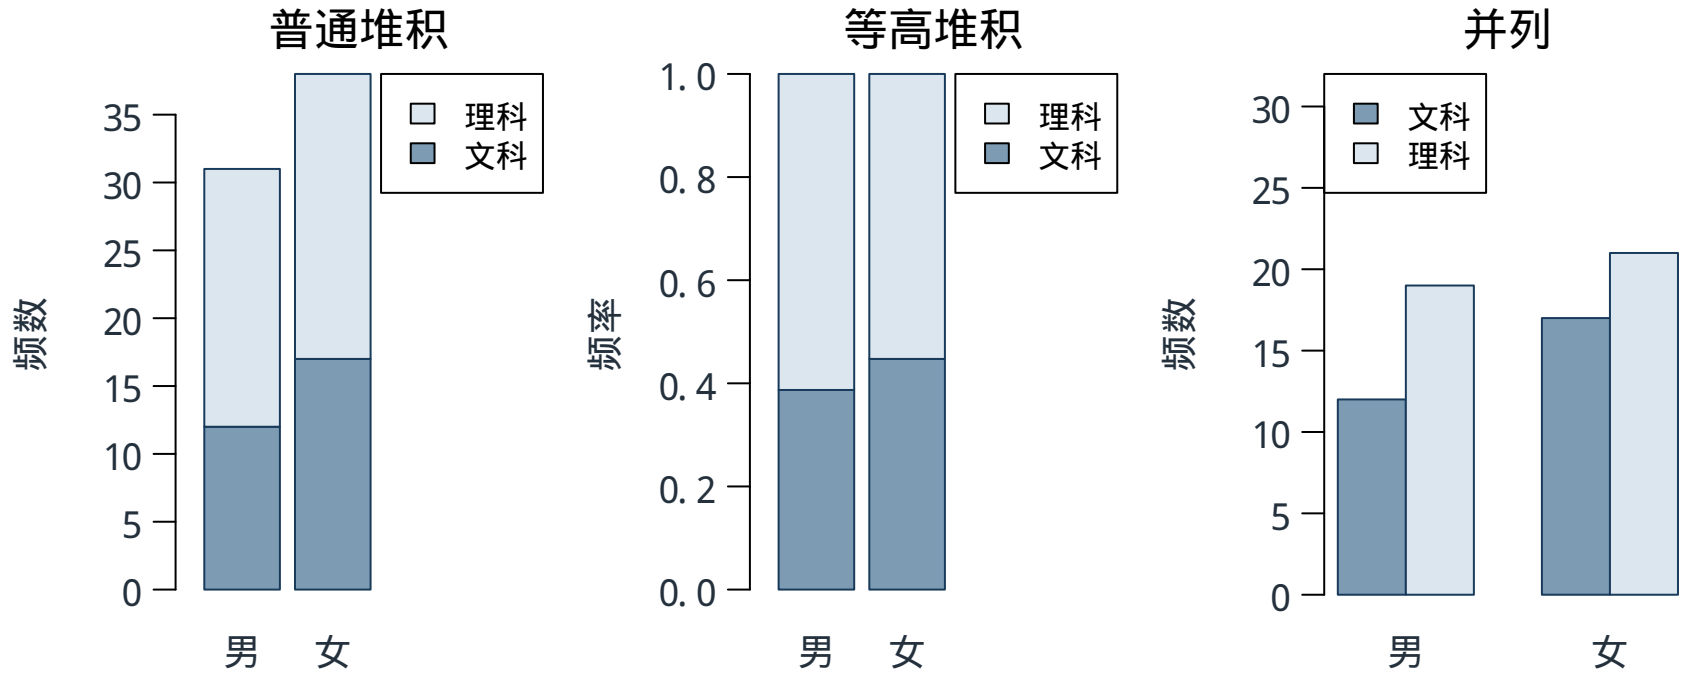

理科总人数最多。
文科女生比例为 $25/40$，理科为 $30/50$，工科为 $15/40$。
比较比例应看各专业内部的分母，而非只看女生人数。

# 本讲操作核对

| 任务 | 使用的方法 |
| --- | --- |
| 连续数值的分布 | `hist()`，明确组边界及纵轴 |
| 分类统计 | `table()`、`prop.table()` |
| 添加合计 | `addmargins()` |
| 分类图形 | `barplot()`、`pie()` |
| 组内比例 | `prop.table(..., margin = 2)` |
| 并列显示 | `beside = TRUE` |

选择图形时，先确定要比较的是数量、比例，还是连续数值的分布形状。

# 参考：交换分类方向后的图形




横轴改为男、女，柱内区分文科、理科。
等高堆积图的分母相应改为
男生 31 人、女生 38 人。

# 参考：Excel 数据导入

教材附录介绍了用 `xlsx` 读取 Excel 数据的方法。

1. 配置与系统相适应的 64 位 Java 环境。
2. 安装 `rJava`、`xlsxjars`、`xlsx`。
3. 加载程序包，再用 `read.xlsx()` 读取数据。

本次课堂直接使用已提供的数据脚本，不要求现场安装上述依赖。

# 参考：程序包加载与读取函数

完成环境配置和安装后，教材给出的加载命令为：

```
library("rJava")
library("xlsxjars")
library("xlsx")
```

加载后使用 `read.xlsx()`。实际读入前需要确定 Excel 文件和工作表。

本讲不展开安装细节及读取参数，
也不要求独立完成导入。